

VERSION FRANÇAISE

Apprentissage automatique

Machine Learning

Louis Fippo Fitime

1er octobre 2024

Traduction fidèle et mise en page adaptée du support original de 60 diapositives.

L'ère de l'automatisation et des systèmes intelligents

- Un potentiel immense dans tous les secteurs et toutes les entreprises.
- Les systèmes intelligents et les organisations pilotées par les données deviennent une réalité.
- Les progrès des outils et des techniques ne font qu'accélérer cette expansion.
- Les données sont le nouveau pétrole, et l'apprentissage automatique fournit un concept et un cadre puissants pour en tirer le meilleur parti.

Objectifs de ce cours (1)

L'idée centrale est de vous donner suffisamment de bases pour comprendre :

- pourquoi nous avons besoin de l'apprentissage automatique ;
- les briques fondamentales de l'apprentissage automatique ;
- ce que l'apprentissage automatique peut aujourd'hui nous apporter.

Vous pourrez ainsi déterminer comment exploiter au mieux l'apprentissage automatique afin de tirer le maximum de vos données.

Objectifs de ce cours (2)

- Comprendre les définitions formelles.
- Maîtriser les concepts et les fondements des algorithmes d'apprentissage.
- Gérer les données.
- Construire, évaluer et déployer des modèles.
- Construire, mettre à l'échelle et déployer des systèmes d'apprentissage automatique de niveau production.

Objectifs de ce cours (3)

Le cours comporte également une dimension pratique :

- des cas d'usage précis ;
- des problèmes concrets ;
- des situations réelles.

Pourquoi faire apprendre les machines ?

- L'expertise humaine est insuffisante dans certains domaines.
- Les situations et les comportements peuvent évoluer continuellement.
- Même lorsque les humains disposent d'une expertise suffisante, il peut être extrêmement difficile de l'expliquer formellement ou de la traduire en tâches informatiques.
- Il faut résoudre à grande échelle des problèmes propres à un domaine, à partir de très grands volumes de données.

Paradigme de programmation traditionnel




Figure 1 — Paradigme de programmation traditionnel

Pourquoi l'apprentissage automatique ?




Figure 2 — Paradigme de programmation en apprentissage automatique

Résoudre un problème d'apprentissage automatique

- Exploiter les données et les journaux produits par les appareils.
- Déterminer les attributs clés susceptibles d'être utiles à la construction d'un modèle.
- Observer et enregistrer les attributs des appareils ainsi que leur comportement sur différentes périodes.
- Fournir ces couples d'entrées et de sorties à un algorithme d'apprentissage automatique approprié.
- Déployer le modèle afin qu'il puisse, pour de nouvelles valeurs, prédire si un appareil se comporte normalement ou risque de provoquer une panne.

Définition générale

Pourquoi avons-nous besoin de l'apprentissage automatique ?

- Prendre des décisions fondées sur les données.
- Gagner en efficacité et passer à l'échelle.

L'apprentissage automatique est le domaine d'étude qui donne aux ordinateurs la capacité d'apprendre sans être explicitement programmés.

Arthur Samuel, 1959

Définition formelle

Un programme informatique est dit apprendre de l'expérience E , relativement à une classe de tâches T et à une mesure de performance P , si sa performance sur les tâches de T , mesurée par P , s'améliore avec l'expérience E .




Figure 3 — Tâche, expérience et performance

La tâche T

Une tâche T peut être qualifiée de tâche d'apprentissage automatique selon le processus ou le flux de travail que le système doit suivre pour traiter des observations ou des échantillons.


- Classification ou catégorisation
- Régression
- Détection d'anomalies
- Annotation structurée
- Traduction
- Regroupement (clustering)
- Transcription

L'expérience E et la performance P

Le processus qui consiste à exploiter un jeu de données composé d'échantillons, afin qu'un algorithme ou un modèle apprenne les motifs qu'ils contiennent, constitue l'expérience E acquise par l'algorithme.

La performance P est généralement une mesure quantitative utilisée pour déterminer dans quelle mesure l'algorithme ou le modèle accomplit la tâche T grâce à l'expérience E.

L'apprentissage automatique : un domaine véritablement multidisciplinaire



Science des données · Intelligence artificielle

Figure 4 — Disciplines qui contribuent à l'apprentissage automatique

Intelligence artificielle

L'art, la science et l'ingénierie qui consistent à créer des agents, des machines et des programmes intelligents.




Figure 5 — Quelques grandes composantes de l'intelligence artificielle

Apprentissage profond

L'apprentissage profond cherche à construire une intelligence artificielle en représentant les données sous la forme d'une hiérarchie de concepts : chaque niveau est construit à partir de niveaux plus simples.




Figure 6 — Comparaison conceptuelle entre apprentissage profond et algorithmes traditionnels, d'après Andrew Ng

Concepts importants de l'apprentissage profond

- Réseaux de neurones artificiels
- Rétropropagation du gradient
- Perceptrons multicouches
- Réseaux neuronaux convolutifs (CNN)
- Réseaux neuronaux récurrents (RNN)
- Réseaux à mémoire à long et court terme (LSTM)
- Autoencodeurs

Illustration d'un réseau de neurones artificiel

Entrée Cachée Sortie




Figure 7 — Architecture type d'un réseau de neurones artificiel

Principales familles de méthodes

1. Selon le degré de supervision humaine

- Apprentissage supervisé
- Apprentissage non supervisé
- Apprentissage semi-supervisé
- Apprentissage par renforcement

2. Selon la capacité à apprendre à partir de données incrémentales

- Apprentissage par lots
- Apprentissage en ligne

3. Selon la manière de généraliser à partir des échantillons

- Apprentissage fondé sur les instances
- Apprentissage fondé sur un modèle

Principe

Les méthodes supervisées utilisent des échantillons de données — les données d'entraînement — accompagnés, pour chaque échantillon, de sorties connues appelées étiquettes ou réponses.

L'objectif principal est d'apprendre une correspondance entre les entrées x et leurs sorties y à partir de nombreux exemples d'entraînement.

Deux grandes familles

- Classification
- Régression

Classification

À partir de ce qu'il a appris pendant l'entraînement, le modèle prédit pour chaque nouvelle entrée une étiquette, une classe ou une réponse de nature catégorielle.




Figure 8 — Illustration d'une tâche de classification

Régression

Les tâches dont l'objectif principal est d'estimer une valeur numérique sont appelées des tâches de régression.




Figure 9 — Modèles de régression pour la prédiction du prix d'une maison

Principe

Le modèle ou l'algorithme cherche à apprendre, sans aide ni supervision, les structures latentes, les motifs et les relations présents dans les données.

Grandes familles de tâches

- Regroupement (clustering)
- Réduction de dimension
- Détection d'anomalies
- Extraction de règles d'association

Regroupement (clustering)

Les méthodes de regroupement recherchent des similarités et des relations entre les échantillons, puis les répartissent en groupes. Les éléments d'un même groupe se ressemblent selon leurs attributs ou caractéristiques intrinsèques.




Figure 10 — Regroupement non supervisé de messages de journal

Réduction de dimension

Ces méthodes réduisent le nombre de variables en extrayant ou en sélectionnant un ensemble de caractéristiques principales ou représentatives.




Figure 11 — Réduction de dimension

Détection d'anomalies

On cherche à repérer des événements ou des observations rares qui, au regard des données historiques, ne se produisent habituellement pas.





Figure 12 — Détection non supervisée d'anomalies

Extraction de règles d'association

L'extraction de règles d'association est une méthode de fouille de données utilisée pour examiner de grands ensembles de transactions et y découvrir des motifs et des règles intéressants.




Figure 13 — Extraction non supervisée de règles d'association

Principe et étapes

Un agent est entraîné à interagir avec un environnement et à améliorer progressivement les actions qu'il y réalise.

1. Préparer l'agent avec un ensemble initial de politiques et une stratégie.
2. Observer l'environnement et son état actuel.
3. Sélectionner la politique optimale et exécuter une action.
4. Recevoir la récompense — ou la pénalité — correspondante.
5. Mettre à jour les politiques si nécessaire.
6. Répéter les étapes 2 à 5 jusqu'à l'apprentissage des politiques les plus efficaces.

Remarque : l'apprentissage par renforcement est une catégorie distincte de l'apprentissage semi-supervisé.

Interaction entre l'agent et l'environnement

L'agent apprend au fil du temps en choisissant des actions, puis en observant leurs conséquences dans un environnement donné.




Figure 14 — Entraînement d'un agent à jouer aux échecs

Panorama de l'apprentissage automatique




Figure 15 — Vue d'ensemble des principales approches

Principaux défis (1)

- Une mauvaise qualité des données entraîne de nombreux problèmes.
- L'acquisition, l'extraction et la récupération des données sont des processus extrêmement fastidieux et chronophages.
- Dans de nombreux cas, les données d'entraînement sont insuffisantes ou de qualité médiocre.
- Les problèmes métier doivent être formulés clairement, avec des buts et des objectifs bien définis.

Principaux défis (2)

- Extraire et concevoir les caractéristiques, notamment lorsqu'elles sont fabriquées manuellement.
- Éviter le surapprentissage et le sous-apprentissage des modèles.
- Faire face au fléau de la dimension : un trop grand nombre de caractéristiques peut devenir un véritable obstacle.
- Déployer dans le monde réel des modèles parfois très complexes.

Applications de l'apprentissage automatique (1)

- Recommandation de produits sur les plateformes de commerce en ligne
- Analyse des sentiments et des émotions
- Détection d'anomalies
- Détection et prévention de la fraude
- Recommandation de contenu : actualités, musique, films, etc.

Applications de l'apprentissage automatique (2)

- Prévisions météorologiques
- Prévisions boursières
- Analyse du panier d'achat
- Segmentation de la clientèle
- Reconnaissance d'objets et de scènes dans les images et les vidéos

Applications de l'apprentissage automatique (3)

- Reconnaissance vocale
- Analyse de l'attrition client
- Prédiction du taux de clics
- Détection et prévention des pannes ou des défauts
- Filtrage des courriels indésirables

Définition

Python est un langage interprété : le code source d'un programme Python est converti en bytecode, puis exécuté par la machine virtuelle Python.

- Le développement en Python est rapide.
- En revanche, sa vitesse d'exécution n'est pas toujours aussi élevée.

Atouts et installation

Atouts

- Facile à apprendre
- Compatible avec plusieurs paradigmes de programmation
- Extensible
- Soutenu par une communauté libre et active

Mettre en place un environnement Python

- Installer séparément Python et les bibliothèques nécessaires.
- Utiliser une distribution préconfigurée comprenant les bibliothèques nécessaires, par exemple Anaconda.

Configurer un environnement Anaconda

Outils et bibliothèques à installer

- Jupyter Notebook
- NumPy
- Pandas
- Scikit-learn
- Theano
- TensorFlow
- Keras
- NLTK — Natural Language Toolkit

Du jeu de données au suivi en production




Figure 16 — Pipeline d'apprentissage automatique

Introduction

- Collecte des données : comprendre les différents mécanismes de récupération selon les types de données.
- Description des données : comprendre les attributs et les propriétés des données collectées.
- Préparation des données : transformer les données afin qu'elles puissent être utilisées pendant la modélisation.
- Visualisation des données : représenter les attributs pour communiquer les résultats, améliorer la compréhension, etc.

Analyse exploratoire des données (1)

L'analyse exploratoire des données — AED, ou EDA en anglais — consiste à analyser un jeu de données et à en résumer les caractéristiques et les enseignements principaux.

C'est l'une des premières étapes d'un projet de science des données : elle permet de mieux comprendre les données.

Liste de contrôle

1. Examiner les variables présentes et les dimensions du jeu de données.
2. Vérifier le type de données de chaque colonne.
3. Encoder les étiquettes pour les problèmes de classification.
4. Rechercher les valeurs manquantes.
5. Produire un résumé descriptif du jeu de données.
6. Examiner la distribution de la variable cible.
7. Regrouper les données selon la variable cible.

Analyse exploratoire des données (2)

Liste de contrôle — visualisation

1. Tracer la distribution de toutes les colonnes.
2. Tracer un diagramme de comptage pour les colonnes catégorielles.
3. Produire une matrice de graphiques par paires.
4. Rechercher les valeurs aberrantes.
5. Construire une matrice de corrélation.
6. Tirer les conclusions de l'analyse exploratoire.

Importer le jeu de données Breast Cancer Wisconsin (Diagnostic)

Le code Python suivant importe les dépendances et les données :

```
# Ce programme importe les dépendances.  
import numpy as np  
import pandas as pd  
from sklearn.preprocessing import LabelEncoder  
  
# Importer le jeu de données  
breast_cancer_data = pd.read_csv('/chemin_vers_les_donnees/data.csv')
```

Examiner les variables et les dimensions du jeu de données

Pour afficher les premières observations, on peut utiliser la fonction `head()` de Pandas :

```
# Afficher les cinq premières lignes du jeu de données  
breast_cancer_data.head()
```

Pour examiner les dimensions du jeu de données :

```
# Afficher le nombre de lignes et de colonnes  
breast_cancer_data.shape
```

Vérifier le type et le nombre de valeurs non nulles

Pour cela, on peut utiliser la fonction `info()` de Pandas :

```
# Afficher les informations relatives au jeu de données  
breast_cancer_data.info()
```

Commentez le type de chaque variable...

Encoder les étiquettes pour une classification

Dans cet exemple, la colonne diagnosis est encodée afin que toutes les colonnes soient numériques : B devient 0 et M devient 1.

```
# Encoder la colonne « diagnosis »
label_encode = LabelEncoder()
labels = label_encode.fit_transform(breast_cancer_data['diagnosis'])
breast_cancer_data['target'] = labels
breast_cancer_data.drop(
    columns=['id', 'diagnosis'], axis=1, inplace=True
)
```

La colonne encodée est stockée dans une nouvelle colonne appelée target. Les colonnes diagnosis et id, devenue inutile, sont ensuite supprimées.

Rechercher les valeurs manquantes

Vérifions maintenant si le jeu de données contient des valeurs manquantes.

```
# Rechercher les valeurs manquantes dans chaque colonne  
breast_cancer_data.isnull().sum()
```

Commentez les résultats...

Résumé descriptif du jeu de données

L'étape suivante consiste à calculer des mesures statistiques sur le jeu de données. On parle de statistiques descriptives, c'est-à-dire d'une synthèse des données. La fonction `describe()` de Pandas permet de les obtenir.

```
# Obtenir des mesures statistiques descriptives  
breast_cancer_data.describe()
```

Commentez les résultats...

Examiner la distribution de la variable cible

On examine ensuite la répartition du jeu de données selon la variable cible afin de détecter un éventuel déséquilibre. Cette étape concerne spécifiquement les problèmes de classification.

```
# Examiner la distribution de la variable cible  
breast_cancer_data['diagnosis'].value_counts()
```

Commentez les résultats...

Regrouper les données selon la variable cible

L'étape suivante consiste à étudier la répartition du jeu de données selon la variable cible afin de détecter un éventuel déséquilibre. Cette étape concerne spécifiquement les problèmes de classification.

```
# Examiner la distribution de la variable cible  
breast_cancer_data['diagnosis'].value_counts()
```

Commentez les résultats...

Premières conclusions

- Le jeu de données contient 569 lignes et 32 colonnes.
- Il ne contient aucune valeur manquante.
- La distribution de la plupart des variables présente une asymétrie à droite.
- Le jeu de données est légèrement déséquilibré : les cas bénins sont plus nombreux que les cas malins.
- Pour la plupart des variables, la moyenne est plus élevée dans les cas malins que dans les cas bénins.

Analyse exploratoire des données (2)

Liste de contrôle — visualisation

1. Tracer la distribution de toutes les colonnes.
2. Tracer un diagramme de comptage pour les colonnes catégorielles.
3. Produire une matrice de graphiques par paires.
4. Rechercher les valeurs aberrantes.
5. Construire une matrice de corrélation.
6. Tirer les conclusions de l'analyse exploratoire.

Regrouper les données selon la variable cible

L'étape suivante consiste à étudier la répartition du jeu de données selon la variable cible afin de détecter un éventuel déséquilibre. Cette étape concerne spécifiquement les problèmes de classification.

```
# Examiner la distribution de la variable cible  
breast_cancer_data['diagnosis'].value_counts()
```

Commentez les résultats...

Importer les bibliothèques de visualisation

```
# Importer les bibliothèques de visualisation
import matplotlib.pyplot as plt
import seaborn as sns
```

Matplotlib et Seaborn sont les deux principales bibliothèques de visualisation de données en Python. Il en existe d'autres, notamment Plotly et GGplot.

Commentez les résultats...

Diagramme de comptage des variables catégorielles

Ce jeu de données ne contient qu'une variable catégorielle, `target`, avec deux catégories : 0 — bénin — et 1 — malin. Une variable catégorielle est représentée par un diagramme de comptage ; une variable numérique, par un graphique de distribution.

```
# Diagramme de comptage de la variable catégorielle  
sns.countplot(x='target', data=breast_cancer_data)
```

Le nombre d'observations portant l'étiquette 0 est supérieur à celui des observations portant l'étiquette 1. Les cas bénins sont donc plus nombreux que les cas malins : le jeu de données est légèrement déséquilibré.

Graphiques de distribution de toutes les colonnes

Les autres colonnes étant numériques, on peut tracer leur distribution. Un graphique de distribution permet de déterminer si les données suivent une loi normale ou présentent une asymétrie.

```
# Tracer la distribution de chaque colonne
for column in breast_cancer_data:
    sns.displot(x=column, data=breast_cancer_data)
```

Lorsque l'asymétrie est importante, des transformations peuvent être nécessaires afin d'obtenir de meilleurs résultats lors de l'entraînement des modèles.

Matrice de graphiques par paires

Une matrice de graphiques par paires représente les relations deux à deux entre les variables d'un jeu de données.

```
# Afficher les relations par paires  
sns.pairplot(nom_du_dataframe)
```

L'objectif est de comprendre les relations entre les variables. Une matrice de corrélation, présentée plus loin, permet également d'étudier ces relations.

Rechercher les valeurs aberrantes

La détection des valeurs aberrantes est une tâche importante. De nombreux modèles — régressions, k plus proches voisins, etc. — y sont sensibles. D'autres, comme les forêts aléatoires, le sont beaucoup moins.

```
# Représenter les valeurs aberrantes de chaque colonne
for column in breast_cancer_data:
    plt.figure()
    breast_cancer_data.boxplot([column])
```

Les points situés au-dessus de la moustache supérieure ou au-dessous de la moustache inférieure représentent des valeurs aberrantes.

Matrice de corrélation

Construire une matrice de corrélation est une étape importante de la visualisation. Elle permet de comprendre les relations entre les variables et facilite la sélection des caractéristiques utiles ainsi que l'élimination des variables non pertinentes ou redondantes.

```
# Calculer et afficher la matrice de corrélation
correlation_matrix = breast_cancer_data.corr()
plt.figure(figsize=(20, 20))
sns.heatmap(
    correlation_matrix, cbar=True, fmt='.1f',
    annot=True, cmap='Blues'
)
plt.savefig('carte_thermique_correlation')
```

Une carte thermique permet de visualiser la corrélation entre les variables.

Conclusions de l'analyse exploratoire

- Le jeu de données ne contient aucune valeur manquante.
- Toutes les variables sont numériques et continues, sauf la colonne cible.
- Pour la plupart des variables, la moyenne est légèrement supérieure à la médiane : leur distribution est asymétrique à droite, comme le montrent les graphiques de distribution.
- Le jeu de données est légèrement déséquilibré : les cas bénins (0) sont plus nombreux que les cas malins (1), comme le montre le diagramme de comptage.
- La moyenne de la plupart des variables est nettement plus élevée pour les cas malins que pour les cas bénins.
- La plupart des variables comportent des valeurs aberrantes.
- La matrice révèle de fortes corrélations entre de nombreuses variables ; certaines pourront donc être supprimées lors de la sélection des caractéristiques.